Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра «Системы обработки информации и управления»

Отчет по лабораторной работе №5

«Ансамбли моделей машинного обучения Часть 1»
по дисциплине «Технологии машинного обучения»

Выполнил:
студент группы ИУ5Ц-83Б
Пронин В.К.
подпись, дата

Проверил:
к.т.н., доц., Гапанюк Ю.Е.
подпись, дата

2026 г.

СОДЕРЖАНИЕ ОТЧЕТА

1. Цель лабораторной работы 3
2. Задание 3
3. Основные характеристики датасета 3
4. Листинг 5
4.1. Изучение данных 5
4.2. Преобразование данных 6
4.3. Описательная статистика 7
4.4. Предобработка данных 10
4.4.1. Пропущенные значения 10
4.4.2. Дубликаты 11
4.5. Отсев до определенного количества уникальных значений 11
4.6. Машинное обучение 13
4.6.1. Деление на обучающей и тестовой выборки 13
4.7. Кодирование признаков – прямое кодирование (One-Hot Encoding) . 13
4.8. Обучение модели 14
4.8.1. LightGBMRegressor 14
4.8.2. CatBoostRegressor 15
4.8.3. BaggingRegressor 17
4.8.4. StackingRegressor 18
4.9. Итог 19
4.9.1. Анализ моделей 19
5. Вывод 20

1. Цель лабораторной работы

Изучение ансамблей моделей машинного обучения. Часть 1.

2. Задание

1) Выберите набор данных (датасет) для решения задачи классификации или регресии.
2) В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3) С использованием метода train_test_split разделите выборку на обучающую и тестовую.
4) Обучите следующие ансамблевые модели:
   - одну из моделей группы бэггинга (бэггинг или случайный лес или сверхслучайные деревья);
   - одну из моделей группы бустинга;
   - одну из моделей группы стекинга.
5) Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

3. Основные характеристики датасета

Название датасета: Набор данных о подержанных автомобилях.

Ссылка: https://www.kaggle.com/datasets/shivanink8/used-cars-dataset

О датасетах

Этот набор данных содержит информацию о различных аспектах примерно 52 подержанных автомобилей из autotrader.com и carfax.com, включая их марку, модель, год выпуска, пробег, пробег по городу и шоссе, мощность, крутящий момент, мощность двигателя, запас топлива, количество цилиндров, количество посадочных мест, количество владельцев, цену, ссылку, состояние, тип, количество дверей, привод на колеса, тип двигателя, уровни оборотов, запас хода спереди, запас хода для переднего привода, запас хода сзади, запас хода для заднего привода и сервисные записи.

Autotrader - хорошо известный веб-сайт по продаже и покупке подержанных автомобилей. Отчеты Carfax содержат данные, относящиеся к

истории автомобиля, такие как количество услуг, типы сервисов, количество владельцев, сообщения о любых авариях и т.д. Таким образом, объединенные данные из обоих этих источников содержат информацию как об автомобиле, так и о его истории.

Имея 24 объясняющие переменные, описывающие различные аспекты подержанных автомобилей в районе Сиэтла, можно предсказать конечную цену автомобилей с помощью регрессии.

Структура данных

Id - индекс

brand - марка

model - модель

year – год выпуска

miles - пробег

city mileage – пробег по городу

highway mileage – пробег по шоссе

horsepower - мощность

torque – крутящий момент

engine capacity litre – мощность двигателя

fuel capacity – запас топлива

num cylinder – количество цилиндров

num set – количество посадочных мест

num owners – количество владельцев

price - цена

link - ссылка

condition - состояние

type - тип

doors – количество дверей

wheel drive – привод на колесах

engine type – тип двигателя

speed levels – уровни оборота

front headroom – запас хода спереди

front legroom - передний запас для переднего привода

rear headroom – запас хода сзади

rear legroom - задний запас для заднего привода

service records - сервисные записи

Выбор признаков для машинного обучения

Для машинного обучения выберем целевой признак - стоимость автомобиля. Сопоставим с остальными признаками, а именно, характеристики и конфигурации автомобиля выявляем примерную стоимость автомобиля.

4. Листинг

4.1.Изучение данных

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 52 entries, 0 to 51
Data columns (total 27 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   id                     52 non-null     int64
 1   brand                  52 non-null     object
 2   model                  52 non-null     object
 3   year                   52 non-null     int64
 4   miles                  52 non-null     int64
 5   city_mileage           52 non-null     int64
 6   highway_mileage        52 non-null     int64
 7   horsepower             52 non-null     int64
 8   torque                 52 non-null     int64
 9   engine_capacity_litre  52 non-null     float64
 10  fuel_capacity          52 non-null     float64
 11  num_cylinder           52 non-null     int64
 12  num_seat               52 non-null     int64
 13  num_owners             52 non-null     int64
 14  price                  52 non-null     int64
 15  link                   52 non-null     object
 16  condition              1 non-null      float64
 17  type                   52 non-null     object
 18  doors                  52 non-null     int64
 19  wheel_drive            52 non-null     int64
 20  engine_type            52 non-null     object
 21  speed_levels           51 non-null     float64
 22  front_headroom         52 non-null     float64
 23  front_legroom          52 non-null     float64
 24  rear_headroom          52 non-null     float64
 25  rear_legroom           52 non-null     float64
 26  service_records        52 non-null     int64
dtypes: float64(8), int64(14), object(5)
memory usage: 11.1+ KB
```

В датасете содержатся 52 строки, имеются 3 различные типы: object, int64 и float64.

Просмотр названий столбцов.

```
df.columns
```

```
Index(['id', 'brand', 'model', 'year', 'miles', 'city_mileage',
       'highway_mileage', 'horsepower', 'torque', 'engine_capacity_litre',
       'fuel_capacity', 'num_cylinder', 'num_seat', 'num_owners', 'price',
       'link', 'condition', 'type', 'doors', 'wheel_drive', 'engine_type',
       'speed_levels', 'front_headroom', 'front_legroom', 'rear_headroom',
       'rear_legroom', 'service_records'],
      dtype='object')
```

Первые и последние пять строк датасета.

```
display(df.head())
display(df.tail())
```

	id	brand	model	year	miles	city_mileage	highway_mileage	horsepower	torque	engine_capacity_litre	...	type	doors	wheel_drive	engine_type	spee
0	3	Chevrolet	Volt LT	2019	27173	43	42	149	294	1.5	...	sedan	4	2	hybrid_gas_electric	
1	6	Hyundai	Elantra SE	2017	76941	29	38	146	132	2.0	...	sedan	4	2	gas	
2	7	Ford	Focus	2014	97027	27	37	159	146	2.0	...	sedan	4	2	gas	
3	8	Honda	Civic	2016	95396	31	42	158	138	1.5	...	sedan	4	2	gas	
4	9	Hyundai	Elantra SE	2019	28405	29	38	147	132	2.0	...	sedan	4	2	gas	

5 rows × 27 columns

	id	brand	model	year	miles	city_mileage	highway_mileage	horsepower	torque	engine_capacity_litre	...	type	doors	wheel_drive	engine_type	speed_lev
47	53	Hyundai	Sonata	2019	33412	23	32	245	260	2.0	...	sedan	4	2	gas	
48	54	Hyundai	Elantra SE	2020	13830	30	40	147	132	2.0	...	sedan	4	2	gas	
49	55	Ford	Fusion	2019	23507	20	29	245	275	2.0	...	sedan	4	2	gas	
50	56	Hyundai	Elantra SE	2020	11296	30	40	147	132	2.0	...	sedan	4	2	gas	
51	57	Honda	Accord	2018	82729	30	38	192	192	1.5	...	sedan	4	2	gas	

5 rows × 27 columns

Приведем к нижнему регистру и удаление лишних пробелов в названиях столбцов.

```
#Приведение к нижнему регистру и удаление лишних пробелов в названиях столбцов
df.columns = df.columns.str.strip().str.lower()
```

4.2.Преобразование данных

```
# Проверим объем занимаемой памяти в Мбайтах до преобразования
print(f'Объем датасета до преобразования: {df.memory_usage(deep=True).sum() / 1024 / 1024:.3f} Мбайт')
```

```
Объем датасета до преобразования: 0.048 Мбайт
```

```
original_memory = df.memory_usage(deep=True).sum()
```

```
# Автоматизируем
def change_type_variable(dateframe, show_print_report=False):
    for name_column in dateframe:
        if(dateframe[name_column].dtype  == 'int64'):
            dateframe[name_column] = dateframe[name_column].astype('int32')
            if(show_print_report):
                print(f'Успешно, преобразовали в другой тип INT32 колонки: {name_column}')
        if(dateframe[name_column].dtype  == 'float64'):
            dateframe[name_column] = dateframe[name_column].astype('float32')
            if(show_print_report):
                print(f'Успешно, преобразовали в другой тип FLOAT32 колонки: {name_column}')
        if(name_column in ['accidents_or_damage', 'one_owner', 'personal_use_only']):
            dateframe[name_column] = dateframe[name_column].astype(bool)
    if not(show_print_report):
        print('Успешно, преобразованы в другой тип')
```

```
# Преобразуем их
change_type_variable(df)
```

```
Успешно, преобразованы в другой тип
```

```
# Проверим объем занимаемой памяти в Мбайтах до преобразования
print(f'Объем датасета после преобразования: {df.memory_usage(deep=True).sum() / 1024 / 1024:.3f} Мбайт')
```

```
Объем датасета после преобразования: 0.044 Мбайт
```

```
optimized_memory = df.memory_usage(deep=True).sum()
```

```
# Узнаем, сколько сэкономили памяти
savings_percentage = (original_memory - optimized_memory) / original_memory * 100
print(f"Сэкономлено {savings_percentage:.2f}% памяти")
```

```
Сэкономлено 9.11% памяти
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 52 entries, 0 to 51
Data columns (total 27 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   id                     52 non-null     int32
 1   brand                  52 non-null     object
 2   model                  52 non-null     object
 3   year                   52 non-null     int32
 4   miles                  52 non-null     int32
 5   city_mileage           52 non-null     int32
 6   highway_mileage        52 non-null     int32
 7   horsepower             52 non-null     int32
 8   torque                 52 non-null     int32
 9   engine_capacity_litre  52 non-null     float32
 10  fuel_capacity          52 non-null     float32
 11  num_cylinder           52 non-null     int32
 12  num_seat               52 non-null     int32
 13  num_owners             52 non-null     int32
 14  price                  52 non-null     int32
 15  link                   52 non-null     object
 16  condition              1 non-null      float32
 17  type                   52 non-null     object
 18  doors                  52 non-null     int32
 19  wheel_drive            52 non-null     int32
 20  engine_type            52 non-null     object
 21  speed_levels           51 non-null     float32
 22  front_headroom         52 non-null     float32
 23  front_legroom          52 non-null     float32
 24  rear_headroom          52 non-null     float32
 25  rear_legroom           52 non-null     float32
 26  service_records        52 non-null     int32
dtypes: float32(8), int32(14), object(5)
memory usage: 6.6+ KB
```

4.3.Описательная статистика

```
df.describe()
```

	id	year	miles	city_mileage	highway_mileage	horsepower	torque	engine_capacity_litre	fuel_capacity	num_cylinder	...	pric
count	52.000000	52.000000	52.000000	52.000000	52.000000	52.000000	52.000000	52.000000	52.000000	52.000000	...	52.00000
mean	31.365385	2018.673077	33901.250000	29.038462	37.423077	176.865385	177.923077	1.832692	14.232692	4.038462	...	21763.42307
std	15.378912	1.396370	22700.646139	5.947356	4.136619	33.793507	47.256433	0.379743	2.603973	0.277350	...	3532.45532
min	3.000000	2014.000000	5000.000000	17.000000	24.000000	143.000000	99.000000	1.400000	7.000000	4.000000	...	13590.00000
25%	18.750000	2018.000000	16454.750000	26.500000	35.750000	152.000000	138.000000	1.500000	12.400000	4.000000	...	19519.00000
50%	31.500000	2019.000000	27448.500000	30.000000	38.000000	159.500000	181.000000	2.000000	13.600000	4.000000	...	21998.50000
75%	44.250000	2019.250000	42442.000000	30.000000	40.000000	192.000000	192.000000	2.000000	15.050000	4.000000	...	22996.00000
max	57.000000	2022.000000	97027.000000	55.000000	49.000000	288.000000	294.000000	3.500000	19.000000	6.000000	...	33777.00000

8 rows × 22 columns

id: Это идентификаторы записей или объектов в данных. Каждая строка имеет уникальный идентификатор. Никаких конкретных выводов о данных не делается на основе этого столбца.

year: Это год выпуска автомобиля. Данные варьируются от 2014 до 2022 года. Средний год выпуска около 2018.7. Большинство автомобилей в диапазоне от 2018 до 2019 года, что может указывать на то, что эти данные собраны за последние несколько лет.

miles: Это количество миль, пройденных автомобилем. Среднее значение составляет около 33901 мили, с большим стандартным отклонением, что может указывать на значительный разброс в пробеге.

city_mileage: Расход топлива в городе, измеренный в милях на галлон. Среднее значение около 29 миль на галлон.

highway_mileage: Расход топлива на шоссе, измеренный в милях на галлон. Среднее значение около 37 миль на галлон.

horsepower: Мощность двигателя в лошадиных силах. Среднее значение около 177.9 лошадиных сил.

torque: Крутящий момент двигателя. Среднее значение около 177.9, что может указывать на связь между мощностью и крутящим моментом.

engine_capacity_litre: Объем двигателя в литрах. Среднее значение около 1.83 литра.

fuel_capacity: Вместимость топливного бака. Среднее значение около 14.23 галлонов.

num_cylinder: Количество цилиндров. Среднее значение около 4.

price: Цена автомобиля. Среднее значение около 21763 доллара. Минимальная цена составляет 13590 долларов, а максимальная - 33777 долларов.

condition: Уровень состояния автомобиля. Все автомобили в данных имеют одинаковый уровень состояния (значение 1.0), что может указывать на единый источник данных или на недостающую информацию.

doors: Количество дверей. Все автомобили имеют 4 двери.

wheel_drive: Тип привода колес. Все автомобили имеют одинаковый тип привода колес (значение 4.0), что может указывать на то, что в данных преобладают автомобили с одним типом привода.

speed_levels: Количество скоростей. Среднее значение около 2.15, что может указывать на то, что в основном автомобили имеют две передачи.

front_headroom, front_legroom, rear_headroom, rear_legroom: Эти столбцы представляют размеры салона автомобиля. Средние значения

указывают на средний размер салона для головы и ног для передних и задних пассажиров.

service_records: Количество записей об обслуживании автомобиля. Среднее значение около 8, что может указывать на среднее количество обслуживаний, которое получает автомобиль.

Большинство автомобилей в данных относятся к периоду с 2018 по 2019 год, что может свидетельствовать о том, что данные собраны за последние несколько лет. Пробег автомобилей варьируется от низкого до высокого, что подтверждает разнообразие данных. Средний расход топлива в городе и на шоссе также отражает разнообразие автомобилей в данных. Цены на автомобили также различаются, что может быть связано с их характеристиками и состоянием. Большинство автомобилей имеют 4 двери и один тип привода колес. Средний уровень состояния автомобилей оценивается как одинаковый для всех записей. В среднем автомобили имеют около 2 передач и средний объем двигателя около 1.83 литра. Средний уровень обслуживания автомобилей составляет около 8 записей.

4.4.Предобработка данных

4.4.1. Пропущенные значения

```
# Создаем список с именами столбцов и количеством пропущенных значений
missing_counts = [df[column].isnull().sum() for column in df.columns]

# Сортируем столбцы в порядке убывания количества пропущенных значений
sorted_columns, sorted_missing_counts = zip(*sorted(zip(df.columns, missing_counts), key=lambda x: x[1], reverse=False))

# Создаем горизонтальную столбчатую диаграмму
plt.figure(figsize=(10, 6))
# Используем barh для горизонтальных столбцов
plt.barh(sorted_columns, sorted_missing_counts)
plt.xlabel('Количество пропущенных значений')
plt.ylabel('Название столбцов')
plt.title('Количество пропущенных значений в каждом столбце')
plt.tight_layout()

# Отображаем график
plt.show()
```

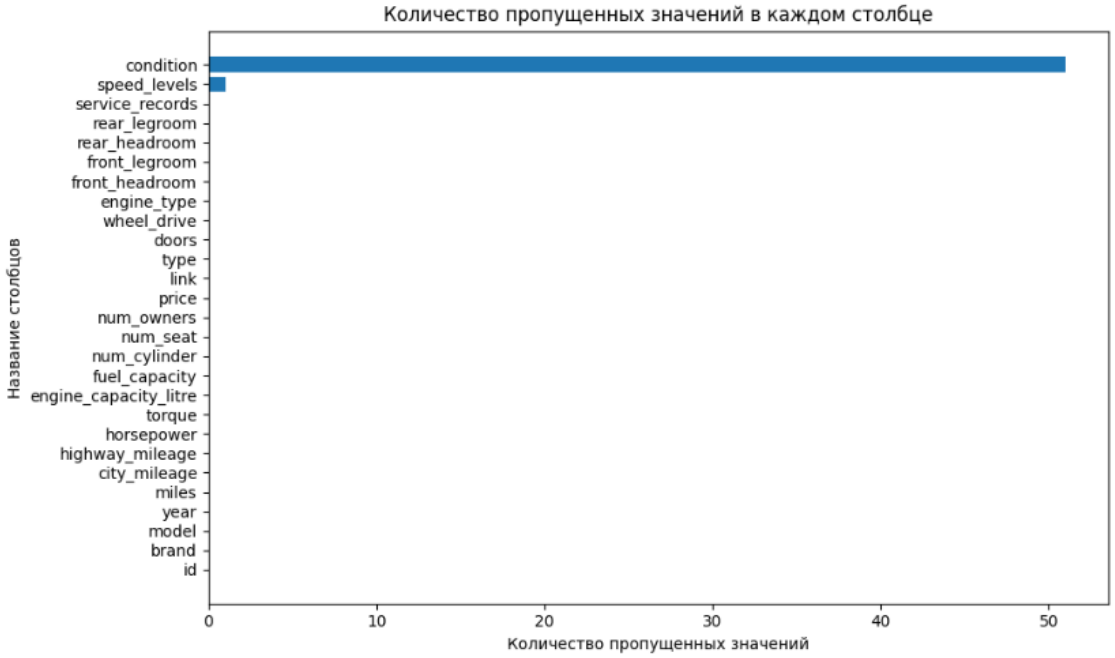

В диаграмме присутствуют большие пропуски в столбцах: состояние и уровни оборота. Заполним пропуски медианными значениями только для численных типов, а остальных типов значения устраняем. Медианными значениями заполняем, потому что они менее чувствительны к выбросам.

```
columns_isnull = [col for col, count in zip(sorted_columns, sorted_missing_counts) if count > 0]
print(f'Названий столбцов, у которых пропуски:')
for col in columns_isnull:
    print('\t' + col)
```

```
Названий столбцов, у которых пропуски:
        speed_levels
        condition
```

```python
# Проверим наличие пустых значений
# Цикл по колонкам датасета
for col in df.columns:
    # Количество пустых значений - все значения заполнены
    temp_null_count = df[df[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

```
id - 0
brand - 0
model - 0
year - 0
miles - 0
city_mileage - 0
highway_mileage - 0
horsepower - 0
torque - 0
engine_capacity_litre - 0
fuel_capacity - 0
num_cylinder - 0
num_seat - 0
num_owners - 0
price - 0
link - 0
condition - 51
type - 0
doors - 0
wheel_drive - 0
engine_type - 0
speed_levels - 1
front_headroom - 0
front_legroom - 0
rear_headroom - 0
rear_legroom - 0
service_records - 0
```

```python
# Замена пропусков медианой для 'speed_levels'
median_speed = df['speed_levels'].median()
df['speed_levels'].fillna(median_speed, inplace=True)

# Замена пропусков медианой для 'condition'
median_condition = df['condition'].median()
df['condition'].fillna(median_condition, inplace=True)
```

```python
# Проверим еще раз
for col in columns_isnull:
    print(f'Колонка: {col}; \t Кол-во пропусков: {df[col].isnull().sum()}')
```

```
Колонка: speed_levels;   Кол-во пропусков: 0
Колонка: condition;      Кол-во пропусков: 0
```

4.4.2. Дубликаты

```python
# Количество дублирующих значений
df.duplicated().sum()
```

```
0
```

Дубликатов нет, это говорится о том, что датасет был хорошо сделан.

4.5.Отсев до определенного количества уникальных значений

Для кодирования признаков OHE или OH будет черевато, если оставить много уникальных названий, т.к. это приведет к созданию много новых признаков. Поэтому отсеиваем до небольших количеств, так чтобы создали максимум небольших новых закодированных признаков.

```python
# Сделаем копию датасета
df_copy = df.copy()
```

```python
df_copy.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 52 entries, 0 to 51
Data columns (total 27 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   id                     52 non-null     int64
 1   brand                  52 non-null     object
 2   model                  52 non-null     object
 3   year                   52 non-null     int64
 4   miles                  52 non-null     int64
 5   city_mileage           52 non-null     int64
 6   highway_mileage        52 non-null     int64
 7   horsepower             52 non-null     int64
 8   torque                 52 non-null     int64
 9   engine_capacity_litre  52 non-null     float64
 10  fuel_capacity          52 non-null     float64
 11  num_cylinder           52 non-null     int64
 12  num_seat               52 non-null     int64
 13  num_owners             52 non-null     int64
 14  price                  52 non-null     int64
 15  link                   52 non-null     object
 16  condition              52 non-null     float64
 17  type                   52 non-null     object
 18  doors                  52 non-null     int64
 19  wheel_drive            52 non-null     int64
 20  engine_type            52 non-null     object
 21  speed_levels           52 non-null     float64
 22  front_headroom         52 non-null     float64
 23  front_legroom          52 non-null     float64
 24  rear_headroom          52 non-null     float64
 25  rear_legroom           52 non-null     float64
 26  service_records        52 non-null     int64
dtypes: float64(8), int64(14), object(5)
memory usage: 11.1+ KB
```

```python
# Функция, которая разделяет численные и категориальные признаки
def divide_features(df):
    numerical_features = df.select_dtypes(include=['number']).columns
    categorical_features = df.select_dtypes(exclude=['number']).columns

    return numerical_features, categorical_features
```

```python
numerical_features, categorical_features = divide_features(df)
```

```python
print("Численные признаки:", numerical_features.to_list())
```

```
Численные признаки: ['id', 'year', 'miles', 'city_mileage', 'highway_mileage', 'horsepower', 'torque', 'engine_capacity_litre', 'fuel_capacity', 'num_cyl
inder', 'num_seat', 'num_owners', 'price', 'condition', 'doors', 'wheel_drive', 'speed_levels', 'front_headroom', 'front_legroom', 'rear_headroom', 'rear
_legroom', 'service_records']
```

```python
print("Нечисленные признаки:", categorical_features.to_list())
```

```
Нечисленные признаки: ['brand', 'model', 'link', 'type', 'engine_type']
```

```python
# Можно закодировать, ибо не так уж много разных уникальных признаков
df_copy['brand'].value_counts()
```

```
brand
Honda         23
Volkswagen    11
Hyundai        7
Ford           5
Chevrolet      3
Subaru         3
Name: count, dtype: int64
```

```python
# Можно закодировать, ибо не так уж много разных уникальных признаков
df_copy['model'].value_counts()
```

```
model
Civic         14
Jetta          7
Accord         7
Elantra SE     4
Passat         4
Fusion         3
Sonata         3
Impreza        2
Malibu         2
Volt LT        1
Focus          1
Legacy         1
Clarity        1
Insight        1
Taurus         1
Name: count, dtype: int64
```

```
# Можно закодировать, ибо не так уж много разных уникальных признаков
df_copy['type'].value_counts()
```

```
type
sedan    52
Name: count, dtype: int64
```

```
# Можно закодировать, ибо не так уж много разных уникальных признаков
df_copy['engine_type'].value_counts()
```

```
engine_type
gas                    49
hybrid_gas_electric     3
Name: count, dtype: int64
```

4.6.Машинное обучение

```
# Здесь сохраняем результаты машинного обучения
results = pd.DataFrame()

# Счетчтик для нумерация моеделй
count_model = 0
```

4.6.1. Деление на обучающей и тестовой выборки

```
# Получаем признак и цель
features = df.drop(['price', 'link'], axis=1)
target = df['price']
```

```
# Разделим на обучающую и тестовую выборку
features_train, features_test, target_train, target_test = train_test_split(features, target, test_size=0.2, random_state=12345)
```

4.7.Кодирование признаков – прямое кодирование (One-Hot Encoding)

Закодируем признаки: brand, model, type, engine type.

```
# Выбираем категориальные признаки
# 'brand', 'model', 'type', 'engine_type'
categorical_features = ['brand', 'model', 'type', 'engine_type']
```

```
# Кодируем
encoder_ohe = OneHotEncoder(drop='first', handle_unknown='ignore', sparse_output=False)
display(encoder_ohe)
```

```
OneHotEncoder
OneHotEncoder(drop='first', handle_unknown='ignore', sparse_output=False)
```

```
# Добавляем закодированные признаки в X_train_ohe
# Encoder_ohe.get_feature_names_out() позволяет получить названия колонок
features_train[encoder_ohe.get_feature_names_out()] = encoder_ohe.transform(features_train[categorical_features])
```

```
# Энкодером, который обучен на тренировочной выборке, кодируем тестовую
features_test[encoder_ohe.get_feature_names_out()] = encoder_ohe.transform(features_test[categorical_features])
```

```
# удаляем незакодированные категориальные признаки (изначальные колонки)
features_train = features_train.drop(categorical_features, axis=1)
features_test = features_test.drop(categorical_features, axis=1)
```

```
display(features_train.head())
display(features_test.head())
```

	id	year	miles	city_mileage	highway_mileage	horsepower	torque	engine_capacity_litre	fuel_capacity	num_cylinder	...	model_Focus	model_Fusion	model_Imp
8	14	2019	25044	30	40	147	184	1.4	13.2	4	...	0.0	0.0	
21	27	2020	35743	20	29	245	275	2.0	18.0	4	...	0.0	1.0	
19	25	2019	24250	30	40	147	184	1.4	13.2	4	...	0.0	0.0	
2	7	2014	97027	27	37	159	146	2.0	12.4	4	...	1.0	0.0	
20	26	2019	38097	17	24	288	254	3.5	19.0	6	...	0.0	0.0	

5 rows × 39 columns

	id	year	miles	city_mileage	highway_mileage	horsepower	torque	engine_capacity_litre	fuel_capacity	num_cylinder	...	model_Focus	model_Fusion	model_Imp
26	32	2020	12395	30	38	192	192	1.5	14.8	4	...	0.0	0.0	
39	45	2020	36506	21	31	245	275	2.0	16.5	4	...	0.0	1.0	
38	44	2018	51279	30	38	192	192	1.5	14.8	4	...	0.0	0.0	
25	31	2020	27457	23	34	174	206	2.0	18.5	4	...	0.0	0.0	
6	12	2022	6811	27	35	182	176	2.5	18.5	4	...	0.0	0.0	

5 rows × 39 columns

```
# Устраняем случайные и возможные пропуски для избежания ошибок
features_train = features_train.dropna()
target_train = target_train[features_train.index]

features_test = features_test.dropna()
target_test = target_test[features_test.index]
```

4.8.Обучение модели

4.8.1. LightGBMRegressor

```
# Матрица гиперпараметров для LGBMRegressor
parameters = {
    'lgbmregressor__n_estimators': [10, 25],
    'lgbmregressor__learning_rate': [0.1, 0.3],
    'lgbmregressor__max_depth': [5, 15],
    'lgbmregressor__num_leaves': [5, 10],
}

# Инициализируем модель с параметрами и создаем конвейер
pipeline_scale = make_pipeline(StandardScaler(), LGBMRegressor())
model = GridSearchCV(pipeline_scale, param_grid=parameters, cv=5, scoring='neg_mean_absolute_error')
display(model)
```

```
GridSearchCV
GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('standardscaler', StandardScaler()),
                                       ('lgbmregressor', LGBMRegressor())]),
             param_grid={'lgbmregressor__learning_rate': [0.1, 0.3],
                         'lgbmregressor__max_depth': [5, 15],
                         'lgbmregressor__n_estimators': [10, 25],
                         'lgbmregressor__num_leaves': [5, 10]},
             scoring='neg_mean_absolute_error')
  estimator: Pipeline
  Pipeline(steps=[('standardscaler', StandardScaler()),
                  ('lgbmregressor', LGBMRegressor())])
    StandardScaler
    StandardScaler()
    LGBMRegressor
    LGBMRegressor()
```

```
%%notify -m f"{pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__}"
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)
time = model.refit_time_
params = model.best_params_

# Узнаем MAE обучающей выборки
result_MAE_t = -model.best_score_
print('MAE TRAIN:', result_MAE_t)
print('TIME TRAIN [s]:', round(time, 2))
```

```
[LightGBM] [Info] Total Bins 50
[LightGBM] [Info] Number of data points in the train set: 41, number of used features: 4
[LightGBM] [Info] Start training from score 21192.365854
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
MAE TRAIN: 2540.615340909091
TIME TRAIN [s]: 0.01
CPU times: total: 3.94 s
Wall time: 840 ms
```

Проверка на тестовой выборки

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборки
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

# Узнаем MAE
result_MAE_v = mean_absolute_error(target_test, predictions)
print('MAE TEST:', result_MAE_v)
print('Предсказание:', predictions.mean())
```

```
MAE TEST: 3981.6298987640275
Предсказание: 20997.089767440866
CPU times: total: 15.6 ms
Wall time: 3 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__,
    'MAE TRAIN': result_MAE_t,
    'MAE TEST': result_MAE_v,
    'PREDICTIONS': predictions.mean(),
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.8.2. CatBoostRegressor

```
# Матрица гиперпараметров для CatBoostRegressor
parameters = {
    'catboostregressor__iterations': [6, 10],
    'catboostregressor__learning_rate': [0.1, 0.5],
    'catboostregressor__depth': [5, 15],
}

# Инициализируем модель с параметрами и создаем конвейер
pipeline_scale = make_pipeline(StandardScaler(), CatBoostRegressor())
model = GridSearchCV(pipeline_scale, param_grid=parameters, cv=5, scoring='neg_mean_absolute_error')
display(model)
```

```
GridSearchCV
GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('standardscaler', StandardScaler()),
                                       ('catboostregressor',
                                        <catboost.core.CatBoostRegressor object at 0x0000025F4A042FA0>)]),
             param_grid={'catboostregressor__depth': [5, 15],
                         'catboostregressor__iterations': [6, 10],
                         'catboostregressor__learning_rate': [0.1, 0.5]},
             scoring='neg_mean_absolute_error')
estimator: Pipeline
Pipeline(steps=[('standardscaler', StandardScaler()),
                ('catboostregressor',
                 <catboost.core.CatBoostRegressor object at 0x0000025F4A042FA0>)])
StandardScaler
StandardScaler()
CatBoostRegressor
<catboost.core.CatBoostRegressor object at 0x0000025F4A042FA0>
```

```
%%notify -m f"{pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__}"
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)
time = model.refit_time_
params = model.best_params_

# Узнаем MAE обучающей выборки
result_MAE_t = -model.best_score_
print('MAE TRAIN:', result_MAE_t)
print('TIME TRAIN [s]:', round(time, 2))
```

```
6:      learn: 1275.3725343     total: 22.3ms   remaining: 9.55ms
7:      learn: 1121.0490273     total: 25.4ms   remaining: 6.34ms
8:      learn: 982.3626057      total: 26.2ms   remaining: 2.91ms
9:      learn: 874.9552891      total: 29.1ms   remaining: 0us
0:      learn: 3001.7465398     total: 809us    remaining: 7.28ms
1:      learn: 2911.4559455     total: 1.45ms   remaining: 5.78ms
2:      learn: 2838.0816943     total: 2.13ms   remaining: 4.97ms
3:      learn: 2755.0242914     total: 2.78ms   remaining: 4.17ms
4:      learn: 2695.0611857     total: 3.37ms   remaining: 3.37ms
5:      learn: 2649.9127631     total: 4.01ms   remaining: 2.67ms
6:      learn: 2560.8949432     total: 4.62ms   remaining: 1.98ms
7:      learn: 2502.0622453     total: 5.21ms   remaining: 1.3ms
8:      learn: 2448.4931413     total: 5.8ms    remaining: 644us
9:      learn: 2374.9448141     total: 6.41ms   remaining: 0us
MAE TRAIN: 2327.7429399863895
TIME TRAIN [s]: 0.03
CPU times: total: 1.11 s
Wall time: 2.19 s
```

Проверка на тестовой выборки

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборки
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

# Узнаем MAE
result_MAE_v = mean_absolute_error(target_test, predictions)
print('MAE TEST:', result_MAE_v)
print('Предсказание:', predictions.mean())
```

```
MAE TEST: 3584.1332071736456
Предсказание: 21432.976140606996
CPU times: total: 0 ns
Wall time: 2.99 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__,
    'MAE TRAIN': result_MAE_t,
    'MAE TEST': result_MAE_v,
    'PREDICTIONS': predictions.mean(),
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.8.3. BaggingRegressor

```
# Матрица гиперпараметров для BaggingRegressor
parameters = {
    'baggingregressor__n_estimators': [10, 50],
    'baggingregressor__random_state': [12345]
}

# Инициализируем модель с параметрами и создаем конвейер
# Инициализируем BaggingRegressor отдельно
bagging_model = BaggingRegressor(estimator=DecisionTreeRegressor(max_depth=10), random_state=12345)
pipeline_scale = make_pipeline(StandardScaler(), bagging_model)
model = GridSearchCV(pipeline_scale, param_grid=parameters, cv=5, scoring='neg_mean_absolute_error')
display(model)
```

```
GridSearchCV
GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('standardscaler', StandardScaler()),
                                       ('baggingregressor',
                                        BaggingRegressor(estimator=DecisionTreeRegressor(max_depth=10),
                                                         random_state=12345))]),
             param_grid={'baggingregressor__n_estimators': [10, 50],
                         'baggingregressor__random_state': [12345]},
             scoring='neg_mean_absolute_error')
estimator: Pipeline
Pipeline(steps=[('standardscaler', StandardScaler()),
                ('baggingregressor',
                 BaggingRegressor(estimator=DecisionTreeRegressor(max_depth=10),
                                  random_state=12345))])
StandardScaler
StandardScaler()
baggingregressor: BaggingRegressor
BaggingRegressor(estimator=DecisionTreeRegressor(max_depth=10),
                 random_state=12345)
estimator: DecisionTreeRegressor
DecisionTreeRegressor(max_depth=10)
DecisionTreeRegressor
DecisionTreeRegressor(max_depth=10)
```

```
%%notify -m f"{pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__}"
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)
time = model.refit_time_
params = model.best_params_

# Узнаем MAE обучающей выборки
result_MAE_t = -model.best_score_
print('MAE TRAIN:', result_MAE_t)
print('TIME TRAIN [s]:', round(time, 2))
```

```
MAE TRAIN: 2225.157638888889
TIME TRAIN [s]: 0.09
CPU times: total: 625 ms
Wall time: 686 ms
```

Проверка на тестовой выборки

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборки
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

# Узнаем MAE
result_MAE_v = mean_absolute_error(target_test, predictions)
print('MAE TEST:', result_MAE_v)
print('Предсказание:', predictions.mean())
```

```
MAE TEST: 3178.1702121212106
Предсказание: 22128.992272727275
CPU times: total: 0 ns
Wall time: 9.99 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__,
    'MAE TRAIN': result_MAE_t,
    'MAE TEST': result_MAE_v,
    'PREDICTIONS': predictions.mean(),
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.8.4. StackingRegressor

```
# Матрица гиперпараметров для CatBoostRegressor
parameters = {
    'stackingregressor__final_estimator__C': [0.1, 1],
    'stackingregressor__final_estimator__kernel': ['linear', 'rbf'],
    'stackingregressor__cv': [3, 5],
}
# Инициализируем базовые модели
base_models = [('dt', DecisionTreeRegressor()), ('knn', KNeighborsRegressor())]

# Инициализируем StackingRegressor с базовыми моделями
stacking_model = StackingRegressor(estimators=base_models, final_estimator=SVR())

# Создаем конвейер
pipeline_scale = make_pipeline(StandardScaler(), stacking_model)

model = GridSearchCV(pipeline_scale, param_grid=parameters, cv=5, scoring='neg_mean_absolute_error')
display(model)
```

```
GridSearchCV
GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('standardscaler', StandardScaler()),
                                       ('stackingregressor',
                                        StackingRegressor(estimators=[('dt',
                                                                       DecisionTreeRegressor()),
                                                                      ('knn',
                                                                       KNeighborsRegressor())],
                                                          final_estimator=SVR()))]),
             param_grid={'stackingregressor__cv': [3, 5],
                         'stackingregressor__final_estimator__C': [0.1, 1],
                         'stackingregressor__final_estimator__kernel': ['linear',
```

```
estimator: Pipeline
Pipeline(steps=[('standardscaler', StandardScaler()),
                ('stackingregressor',
                 StackingRegressor(estimators=[('dt', DecisionTreeRegressor()),
                                               ('knn', KNeighborsRegressor())],
                                   final_estimator=SVR()))])
StandardScaler
StandardScaler()
stackingregressor: StackingRegressor
StackingRegressor(estimators=[('dt', DecisionTreeRegressor()),
                              ('knn', KNeighborsRegressor())],
                  final_estimator=SVR())
dt
DecisionTreeRegressor
DecisionTreeRegressor()
knn
KNeighborsRegressor
KNeighborsRegressor()
final_estimator
SVR
SVR()
```

```
%%notify -m f"{pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__}"
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)
time = model.refit_time_
params = model.best_params_

# Узнаем MAE обучающей выборки
result_MAE_t = -model.best_score_
print('MAE TRAIN:', result_MAE_t)
print('TIME TRAIN [s]:', round(time, 2))
```

```
MAE TRAIN: 2444.185583304496
TIME TRAIN [s]: 0.04
CPU times: total: 1.48 s
Wall time: 1.62 s
```

Проверка на тестовой выборки

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборки
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

# Узнаем MAE
result_MAE_v = mean_absolute_error(target_test, predictions)
print('MAE TEST:', result_MAE_v)
print('Предсказание:', predictions.mean())
```

```
MAE TEST: 3390.9171341585766
Предсказание: 21986.75415390602
CPU times: total: 0 ns
Wall time: 6 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': pipeline_scale.named_steps[pipeline_scale.steps[-1][0]].__class__.__name__,
    'MAE TRAIN': result_MAE_t,
    'MAE TEST': result_MAE_v,
    'PREDICTIONS': predictions.mean(),
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.9.Итог

4.9.1. Анализ моделей

```
%%notify -m "Total result"
results = pd.DataFrame(results).T
```

Рассмотрим и еще другие модели, которые применялись в предыдущих лабораторных работах: №3 и №4.

```
results
```

	NAME	MAE TRAIN	MAE TEST	PREDICTIONS	TIME TRAINING [s]	TIME PREDICTION [s]	PARAMETRS
0	KNeighborsRegressor	2198.256156	3388.90885	21466.54196	0.002	0.006	{'kneighborsregressor__n_neighbors': 2, 'kneig...
1	LinearRegression	45714.271299	2564.561754	22000.042425	0.002966	0.002	{}
2	DecisionTreeRegressor	2225.75394	3383.304813	22004.529412	0.002998	0.001	{'decisiontreeregressor__max_depth': 1, 'decis...
3	SVR	2207.794027	3541.972537	21602.169682	0.001999	0.001	{'svr__C': 10, 'svr__gamma': 'scale', 'svr__ke...
4	LGBMRegressor	2540.615341	3981.629899	20997.089767	0.005002	0.003	{'lgbmregressor__learning_rate': 0.1, 'lgbmreg...
5	CatBoostRegressor	2327.74294	3584.133207	21432.976141	0.033211	0.003	{'catboostregressor__depth': 5, 'catboostregre...
6	BaggingRegressor	2225.157639	3178.170212	22128.992273	0.086585	0.01	{'baggingregressor__n_estimators': 50, 'baggin...
7	StackingRegressor	2444.185583	3390.917134	21986.754154	0.03655	0.006	{'stackingregressor__cv': 5, 'stackingregresso...

```python
# Рассчитываем рейтинг с учетом указанных приоритетов
results['RATING'] = (
    0.5 * (1 - (results['MAE TEST'] / results['MAE TEST'].max())) +
    0.3 * (1 - (results['TIME TRAINING [s]'] / results['TIME TRAINING [s]'].max())) +
    0.2 * (1 - (results['TIME PREDICTION [s]'] / results['TIME PREDICTION [s]'].max()))
)
# Сортируем DataFrame по убыванию рейтинга
results = results.sort_values(by='RATING', ascending=False)
```

```python
results
```

	NAME	MAE TRAIN	MAE TEST	PREDICTIONS	TIME TRAINING [s]	TIME PREDICTION [s]	PARAMETRS	RATING
1	LinearRegression	45714.271299	2564.561754	22000.042425	0.002966	0.002	{}	0.627673
2	DecisionTreeRegressor	2225.75394	3383.304813	22004.529412	0.002998	0.001	{'decisiontreeregressor__max_depth': 1, 'decis...	0.544749
3	SVR	2207.794027	3541.972537	21602.169682	0.001999	0.001	{'svr__C': 10, 'svr__gamma': 'scale', 'svr__ke...	0.528283
0	KNeighborsRegressor	2198.256156	3388.90885	21466.54196	0.002	0.006	{'kneighborsregressor__n_neighbors': 2, 'kneig...	0.447502
4	LGBMRegressor	2540.615341	3981.629899	20997.089767	0.005002	0.003	{'lgbmregressor__learning_rate': 0.1, 'lgbmreg...	0.422667
5	CatBoostRegressor	2327.74294	3584.133207	21432.976141	0.033211	0.003	{'catboostregressor__depth': 5, 'catboostregre...	0.374846
7	StackingRegressor	2444.185583	3390.917134	21986.754154	0.03655	0.006	{'stackingregressor__cv': 5, 'stackingregresso...	0.32754
6	BaggingRegressor	2225.157639	3178.170212	22128.992273	0.086585	0.01	{'baggingregressor__n_estimators': 50, 'baggin...	0.100896

Модель SVR имеет наименьшую среднюю абсолютную ошибку на обучающем наборе, что может указывать на то, что она лучше всего подгоняется под обучающие данные. В то время как модели DecisionTreeRegressor, KNeighborsRegressor и BaggingRegressor также имеют низкие значения MAE TRAIN, что указывает на их хорошую подгонку под обучающий набор данных. В то время как другие модели имеют более высокие значения MAE TRAIN, что может указывать на их менее точное соответствие обучающим данным.

5. Вывод

В ходе лабораторной работы изучили ансамбли моделей машинного обучения.